A/B-тест геймификации в образовательной платформе

Сегментный анализ по классам 5–11

Аналитика продукта

A/B-эксперимент
3 недели · 5 980 пользователей

2026-05-24

Резюме за 30 секунд

Что проверяли:
механика достижений за регулярное решение задач.

Что нашли:
эффект **крайне неоднороден по классам**.

Решение:
раскатить сегментно на **5–9**,
доработать для **10–11**.

Параметр	Значение
Период	3 недели
Всего пользователей	5 980
Группа A (контроль)	2 992
Группа B (тест)	2 988
Классы	5–11
Метрик в семействе	9
Значимо после Holm	**9 из 9**

Проблема и гипотеза

Проблема:

- падение retention после первого ДЗ;
- длинный time-to-value (медиана $>$ 50 часов).

Гипотеза:
геймификация увеличит retention и completion rate.

Что мерим:

- **ключевые:** retention_7, retention_14;
- **вторичные:** completion_flag, solved_rate;
- **дополнительные:** TTFV, active_days.

Дизайн эксперимента

Параметр	Значение
α (ошибка I рода)	0.05
Power $(1 - \beta)$	0.80
Тест	двусторонний
Множественные сравнения	Holm–Bonferroni (9 метрик)
Practically significant (completion)	+2 п.п.
Practically significant (retention)	+3 п.п.
MDE (retention_7)	+3.2 п.п.
MDE (retention_14)	+3.3 п.п.

Данные и очистка

Этап	users	events
Сырые данные	6 008	179 330
– дубли строк	6 008	179 328
– user_id в A и B (8)	5 992	179 111
– боты (12)	**5 980**	**169 833**

Что удалили:

- 8 user_id попали в A и B одновременно — нарушение рандомизации;
- 12 ботов: ≥ 500 событий на пользователя;
- пересечение ботов и выбросов: 12 из 12.

SRM и валидность сплита

Проверка	Статистика	p-value	Вывод
SRM (users)	$\chi^2 = 0.0027$	0.9587	**OK**
SRM (events)	$\chi^2 = 0.0027$	0.9587	**OK**
Пересечение A ∩ B	0	—	**OK**
grade × group	$\chi^2 = 8.01$, df=6	0.237	**OK**
signup_date (KS)	$D = 0.028$	0.178	**OK**
signup_month × group	$\chi^2 = 19.95$, df=13	0.096	**OK**

Эксперимент валиден.

Общие результаты

Метрика	A	B	Δ	p (Holm)
retention_14	0.288	0.363	+7.43 **п.п.**	2.5×10^{-9}
retention_7	0.727	0.780	+5.28 **п.п.**	4.3×10^{-6}
solved_rate	0.346	0.438	+0.092	9.5×10^{-94}
completion_flag	0.976	0.988	+1.20 п.п.	4.3×10^{-4}
TTFV (медиана, ч)	50.3	25.2	−25.1 **ч**	7.5×10^{-23}

Все 9 метрик значимы после Holm–Bonferroni.

Не достигнут practically significant: completion_flag ($+1.20 < +2$) — упирается в потолок 97.6 %.

Главный результат: эффект неоднороден по классам

Класс	retention_7	retention_14	solved_rate	completed_cnt
5	+9.6	+15.0	+0.19	+3.5
6	+11.0	+15.8	+0.21	+4.0
7	+14.0	+17.8	+0.14	+2.0
8	+3.9	+5.7	+0.10	+2.0
9	+6.7	+5.3	+0.11	+2.0
10	−1.5	−5.5	−0.048	−1.0
11	−6.8	−2.6	−0.048	−1.0

- 5–7: сильный положительный ($p < 10^{-6}$)
- 8–9: умеренный положительный ($p < 10^{-10}$)
- 10–11: нулевой или **значимый регресс**

Time to Value

Показатель	A	B	Δ
Медиана TTFV	50.3 ч	25.2 ч	−50 %
75 % квартиль	141.0 ч	95.7 ч	−32 %
Доля < 24 ч	35.8 %	46.9 %	**+11.1 п.п.**
Доля > 7 дней	18.8 %	12.4 %	−6.4 п.п.

Скорость первого completed улучшилась в 2 раза.
Доля «быстрых» выросла, «медленных» упала.

Проверка устойчивости

Проверка	Результат
Парадокс Симпсона	Нет
Устойчивость к выбросам (top-1 %)	Сдвиг $< 15\,\%$ по всем метрикам
Bootstrap 10 000 повторов	Ни один CI не включает 0
Альтернативные определения retention_7	$+5.28$ / $+4.99$ / $+1.13$ п.п.

Красный флаг: величина retention_7 сильно зависит от определения:

- платформенное событие: $+5.28$ **п.п.**
- exact day 7: $+4.99$ п.п.
- окно 5–9 дней: $+1.13$ **п.п.**

Знак устойчив, величина — нет. Требуется аудит методики.

Рекомендация

Раскатить сегментно на классы 5–9.
Не раскатывать на 10–11 до доработки.

Сегмент	n	retention_14	Решение	Риск
5–7	2 607	$+15.0 \ldots +17.8$	Раскатить	низкий
8–9	1 694	$+5.3 \ldots +5.7$	Раскатить	низкий
10	847	-5.5 **(ns)**	Доработка	высокий
11	832	-2.6 **(ns)**	Доработка	высокий

Уверенность: высокая ($n \approx 400$–460 на группу, $p < 10^{-6}$ в 5–7).

План внедрения

#	Действие	Ответственный	Срок	Stop/Go
1	Согласовать rollout 5–9	Продакт	1 нед	GO / NO-GO
2	Аудит методики return_visit	DE + аналитик	2 нед	при загрязнении — пересмотр
3	Интервью с 10–11	UX	2 нед	$n \geq 15$
4	Раскат на 5–9	Разработка	2 нед	чек-лист
5	Мониторинг 4 недели	Аналитик	4 нед	$<$ baseline $+50\,\%$ эффекта $\rightarrow$ STOP
6	Решение по 10–11	PM + аналитик	6 нед	доработка / отказ
7	Финальный отчёт	Аналитик	8 нед	—

Ожидаемый эффект после раската на 5–9:
retention_7: $+6 \ldots +14$ п.п., retention_14: $+5 \ldots +18$ п.п., solved_rate: $+0.10 \ldots +0.21$.

Что НЕ делать и триггеры пересмотра

Что НЕ делать:

- Не раскатывать на всех — 10–11 получат регресс.
- Не отказываться от фичи — в 5–7 эффект слишком крупный.
- Не считать общий срез — он обманчиво положительный из-за весов.
- Не использовать completion_flag как показатель — потолок 97.6 % в контроле.

Триггеры пересмотра:

1. retention_7 в 5–7 через 4 недели $< +5$ п.п. — эффект затухает.
2. Аудит покажет загрязнение событий — пересмотр всего анализа.
3. Метрики 10–11 без фичи тоже растут — эффект был не в фиче.
4. retention_14 в 5–7 падает ниже baseline при раскате — rollback.

Ограничения

- Горизонт 3 недели — долгосрочный эффект неизвестен.
- Методика `return_visit_d7/d14` не проверена — оценка retention_7 может быть завышена.
- Причина регресса в 10–11 не установлена (ОГЭ/ЕГЭ, дизайн, демотивация).
- Бизнес-метрики (LTV, выручка) не учитывались.
- Внешние факторы (праздники, релизы, маркетинг) как влияние на группы не проверялись.

Спасибо. Вопросы?